0.0.0.0.1. Modelo de Regresión de Poisson

Dado que la variable respuesta es discreta y de tipo conteo, se ha elegido este modelo en el que se asume que el volumen de ventas diario sigue una distribución de Poisson.

$$Y \sim Po(\mu), \quad \mu = \text{Número medio de ventas diario}$$

Partición de los datos:

Se ha tomado una partición de 80 % 20 % para datos de entrenamiento y testeo, con el objetivo de entrenar el modelo para posteriormente estudiar su rendimiento.

0.0.0.0.1.1. Modelado

En primer lugar, estimaremos los parámetros del modelo de regresión de Poisson, utilizando un conjunto de datos con variables dummy para el día de la semana y el mes del año, con la intención de representar la pertenencia de cada instancia a los distintos grupos.

También entrenaremos un modelo haciendo uso del conjunto de datos con las variables día de la semana y mes en forma de factor, para comprobar que modelo nos da unas mejores métricas.

Las variables explicativas son las siguientes:

- Variables dummy/factorizadas del día de la semana y el mes del año
- Precio medio con impuestos y descuento
- Día de la semana
- Mes del año

Ventas totales

```
ModeloP_TOT_dummy =
  glm(VENTAS~PRECIO_MEDIO_IMPUESTOS*DESCUENTO_MEDIO+
                (LUNES+MARTES+MIERCOLES+JUEVES+VIERNES+SABADO+DOMINGO)+
                (AGOSTO+SEPTIEMBRE+OCTUBRE+NOVIEMBRE+DICIEMBRE+ENERO),
      family = poisson(link = "log"),
      data=Ventas_TOTAL_ENT_poiss)
summary(ModeloP_TOT_dummy)
```

```
##
## Call:
## glm(formula = VENTAS ~ PRECIO_MEDIO_IMPUESTOS * DESCUENTO_MEDIO +
##     (LUNES + MARTES + MIERCOLES + JUEVES + VIERNES + SABADO +
##         DOMINGO) + (AGOSTO + SEPTIEMBRE + OCTUBRE + NOVIEMBRE +
##     DICIEMBRE + ENERO), family = poisson(link = "log"), data = Ventas_TOTAL_ENT_po
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -51.810   -6.571    1.080    4.994   64.707
##
## Coefficients: (2 not defined because of singularities)
##                                        Estimate Std. Error z value Pr(>|z|)
## (Intercept)                          -32.219952   0.955000 -33.738  < 2e-16
```

```
## PRECIO_MEDIO_IMPUESTOS                    26.098720   0.663672  39.325  < 2e-16
## DESCUENTO_MEDIO                            2.655409   3.725073   0.713    0.476
## LUNES1                                     2.503693   0.015988 156.601  < 2e-16
## MARTES1                                    2.415363   0.016009 150.873  < 2e-16
## MIERCOLES1                                 2.365094   0.016268 145.386  < 2e-16
## JUEVES1                                    2.595014   0.016010 162.082  < 2e-16
## VIERNES1                                   2.402489   0.016007 150.085  < 2e-16
## SABADO1                                    2.500752   0.016010 156.204  < 2e-16
## DOMINGO1                                         NA         NA      NA       NA
## AGOSTO1                                   -0.254510   0.006886 -36.962  < 2e-16
## SEPTIEMBRE1                               -0.125003   0.006765 -18.479  < 2e-16
## OCTUBRE1                                   0.108339   0.006135  17.660  < 2e-16
## NOVIEMBRE1                                -0.077361   0.007198 -10.748  < 2e-16
## DICIEMBRE1                                -0.034890   0.006418  -5.436 5.44e-08
## ENERO1                                           NA         NA      NA       NA
## PRECIO_MEDIO_IMPUESTOS:DESCUENTO_MEDIO    -1.825982   2.588410  -0.705    0.481
##
## (Intercept)                              ***
## PRECIO_MEDIO_IMPUESTOS                   ***
## DESCUENTO_MEDIO
## LUNES1                                   ***
## MARTES1                                  ***
## MIERCOLES1                               ***
## JUEVES1                                  ***
## VIERNES1                                 ***
## SABADO1                                  ***
## DOMINGO1
## AGOSTO1                                  ***
## SEPTIEMBRE1                              ***
## OCTUBRE1                                 ***
## NOVIEMBRE1                               ***
## DICIEMBRE1                               ***
## ENERO1
## PRECIO_MEDIO_IMPUESTOS:DESCUENTO_MEDIO
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##     Null deviance: 102206  on 144  degrees of freedom
## Residual deviance:  25019  on 130  degrees of freedom
## AIC: 26371
##
## Number of Fisher Scoring iterations: 4
```

En la salida, podemos ver en la columna *estimate* la estimación de los coeficientes de regresión para las distintas variables, indicando, para las variables numérias, el cambio medio en el número de ventas que se produciría si aumentáramos en una unidad esa variable, y para las variables discretas, el cambio medio que provocaría en el número de

ventas el que la variable tomara o no ese valor. También encontramos una columna para el error estándar, el valor del estadístico Z y el p-valor.

Todas las variables que se refieren a meses o días de la semana influyen en el volumen de ventas:

- Con respecto al día de la semana, sabemos que el día de la semana que más ventas hay es el Sábado, por lo que estudiamos como afectan las ventas si es o no este día del fin de semana. $\hat{\beta}_{\text{Sábado}} = 2.500752 > 0$, es decir, el volumen de ventas aumentará, en media $e^{2.500752} = 12$ unidades si la compra se realiza un Sábado
- El mes donde hubo más ventas fué durante el mes de Octubre, y según este modelo el volumen de ventas aumentará, en media, manteniendo el resto de variables constante en $e^{0.108339} = 1$ unidades si la compra se hace durante este mes.

Además, la interacción entre las variables descuento y precio medio también es significativa, es decir, la asociación que existe entre ambas varía en función de los diferentes valores que tomen.

Vamos ahora a entrenar el modelo para las variables factorizadas:

```
ModeloP_TOT_factor= glm(VENTAS~PRECIO_MEDIO_IMPUESTOS+
                          DIA_SEMANA*MES+DESCUENTO_MEDIO,
                        family = poisson(link = "log"),
                        data=Ventas_TOTAL_ENT)
summary(ModeloP_TOT_factor)
```

```
##
## Call:
## glm(formula = VENTAS ~ PRECIO_MEDIO_IMPUESTOS + DIA_SEMANA *
##     MES + DESCUENTO_MEDIO, family = poisson(link = "log"), data = Ventas_TOTAL_ENT
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -44.212   -3.094    0.479    3.585   58.763
##
## Coefficients:
##                            Estimate Std. Error z value Pr(>|z|)
## (Intercept)              -29.399611   1.113717 -26.398  < 2e-16 ***
## PRECIO_MEDIO_IMPUESTOS    25.846617   0.772717  33.449  < 2e-16 ***
## DIA_SEMANA2               -0.040739   0.015208  -2.679 0.007391 **
## DIA_SEMANA3               -0.269271   0.019286 -13.962  < 2e-16 ***
## DIA_SEMANA4                0.039848   0.021983   1.813 0.069883 .
## DIA_SEMANA5                0.060860   0.013909   4.376 1.21e-05 ***
## DIA_SEMANA6                0.086613   0.013002   6.662 2.71e-11 ***
## DIA_SEMANA7               -2.802053   0.048116 -58.235  < 2e-16 ***
## MES8                      -0.004214   0.014360  -0.293 0.769186
## MES9                       0.076174   0.015402   4.946 7.58e-07 ***
## MES10                     -0.089625   0.015596  -5.747 9.10e-09 ***
## MES11                     -0.073488   0.013666  -5.378 7.55e-08 ***
## MES12                     -0.003946   0.015205  -0.260 0.795238
## DESCUENTO_MEDIO            0.063439   0.008285   7.657 1.90e-14 ***
```

```
## DIA_SEMANA2:MES8        -0.179717   0.022960  -7.827 4.99e-15 ***
## DIA_SEMANA3:MES8        -0.090149   0.025918  -3.478 0.000505 ***
## DIA_SEMANA4:MES8        -0.415099   0.028027 -14.811  < 2e-16 ***
## DIA_SEMANA5:MES8        -0.309014   0.021824 -14.159  < 2e-16 ***
## DIA_SEMANA6:MES8        -0.435314   0.020480 -21.256  < 2e-16 ***
## DIA_SEMANA7:MES8         0.329373   0.061599   5.347 8.94e-08 ***
## DIA_SEMANA2:MES9        -0.221695   0.022066 -10.047  < 2e-16 ***
## DIA_SEMANA3:MES9         0.113470   0.024429   4.645 3.40e-06 ***
## DIA_SEMANA4:MES9        -0.338998   0.028216 -12.015  < 2e-16 ***
## DIA_SEMANA5:MES9        -0.598435   0.023369 -25.608  < 2e-16 ***
## DIA_SEMANA6:MES9        -0.195576   0.022563  -8.668  < 2e-16 ***
## DIA_SEMANA7:MES9         0.719879   0.062623  11.495  < 2e-16 ***
## DIA_SEMANA2:MES10        0.193201   0.022172   8.714  < 2e-16 ***
## DIA_SEMANA3:MES10        0.281635   0.025615  10.995  < 2e-16 ***
## DIA_SEMANA4:MES10        0.565819   0.026597  21.274  < 2e-16 ***
## DIA_SEMANA5:MES10        0.021127   0.020549   1.028 0.303888
## DIA_SEMANA6:MES10        0.177425   0.020087   8.833  < 2e-16 ***
## DIA_SEMANA7:MES10        0.506864   0.060592   8.365  < 2e-16 ***
## DIA_SEMANA2:MES11       -0.111932   0.021915  -5.107 3.27e-07 ***
## DIA_SEMANA3:MES11       -0.033636   0.033058  -1.018 0.308910
## DIA_SEMANA4:MES11       -0.062049   0.026811  -2.314 0.020651 *
## DIA_SEMANA5:MES11       -0.024749   0.019503  -1.269 0.204439
## DIA_SEMANA6:MES11        0.140983   0.019330   7.293 3.02e-13 ***
## DIA_SEMANA7:MES11        0.023367   0.061702   0.379 0.704904
## DIA_SEMANA2:MES12        0.005424   0.021705   0.250 0.802669
## DIA_SEMANA3:MES12        0.201484   0.024466   8.235  < 2e-16 ***
## DIA_SEMANA4:MES12        0.149292   0.026123   5.715 1.10e-08 ***
## DIA_SEMANA5:MES12       -0.187272   0.021809  -8.587  < 2e-16 ***
## DIA_SEMANA6:MES12       -0.501937   0.024909 -20.151  < 2e-16 ***
## DIA_SEMANA7:MES12        0.303646   0.060343   5.032 4.85e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##     Null deviance: 102206  on 144  degrees of freedom
## Residual deviance:  19286  on 101  degrees of freedom
## AIC: 20696
##
## Number of Fisher Scoring iterations: 5
```

- La variable *descuento* puede considerarse significativa, y según la estimación del coeficiente $\hat{\beta}_{\text{descuento}} = 0.030274 > 0$ podemos afirmar lo siguiente: manteniendo el resto de variables constantes, un aumento de la variable descuento en una unidad, hará que el volumen de ventas aumente en: $e^{0.030274} = 1$ unidades.
- En este caso, para la variable Sábado podemos decir que si el día de la semana es sábado y manteniendo constantes el resto de variables, el volumen de ventas disminuirá en $e^{-0.296949} = 1$ unidad.

DATOS	R2	RMSE
Datos entrenamiento	0.7066326	593.1505
Datos Test	0.2395861	777.0907

- Para el mes de Octubre, y según este modelo, el volumen de ventas disminuirá, en media, manteniendo el resto de variables constante en $e^{-0.264921} = 1$ unidades si la compra se hace durante este mes.
- Además, la interacción entre las variables día de la semana y mes del año es significativa, indicando que la asociación que existe entre ambas varía en función de los distintos valores que toman.

Para seleccionar un modelo adecuado, se ha hecho uso del criterio de información de Akaike, eligiendo aquel que nos de el menor AIC. A continuación se exponen los correspondientes valores del AIC para ambos modelos:

- Modelo con variables dummy: AIC=26371
- Modelo con variables factorizadas: AIC=20696

El modelo seleccionado es el modelo para variables factorizadas, que nos da el menor valor del AIC, indicación de una mayor calidad del modelo estadístico.

A continuación, procedemos a entrenar el modelo seleccionado en los datos de entrenamiento haciendo uso de la función *predict*

A continuación mostramos una tabla con las métricas que nos dan el rendimiento del modelo

El modelo obtenido explica el 70.66 % de la variabilidad total de los datos en el conjunto de entrenamiento, y el 23.96 % para los datos de testeo, no pudiendo considerar este como un buen modelo para explicar el volumen de ventas total. El valor del error cuadrático medio indica que el modelo se va a equivocar de media, en 777 ventas, que es un valor alto para el volumen de ventas que se está considerando, ya que hay días que se venden menos de 700 items.

Para comprobar si se trata o no de un buen modelo, realizamos el contraste de bondad de ajuste, donde se contrastan las siguientes hipótesis:

$$\begin{cases} H_0: & \text{El ajuste lineal es bueno} \\ H_1: & \text{El ajuste no es bueno} \end{cases}$$

El p-valor del contraste: $0 < 0.05 = \alpha$ y por tanto, no existen evidencias significativas para afirmar que el modelo es adecuadao

Ventas de productos con calcio

```
ModeloP_CALCIO_dummy =
  glm(VENTAS~PRECIO_MEDIO_IMPUESTOS+
               (LUNES+MARTES+MIERCOLES+JUEVES+VIERNES+SABADO+DOMINGO)+
               (AGOSTO+SEPTIEMBRE+OCTUBRE+NOVIEMBRE+DICIEMBRE+ENERO),
             family = poisson(link = "log"),
             data=Ventas_CALCIO_ENT_poiss)
#summary(ModeloP_CALCIO_dummy)
```

DATOS_C	R2_C	RMSE_C
Datos entrenamiento	0.6519377	359.9727
Datos Test	0.1703046	489.6647

```
ModeloP_CALCIO_factor=
  glm(VENTAS~PRECIO_MEDIO_IMPUESTOS+DIA_SEMANA*MES,
              family = poisson(link = "log"),
              data=Ventas_CALCIO_ENT)
#summary(ModeloP_CALCIO_factor)
```

Para ambos modelos podemos afirmar:

- La variable precio medio es altamente significativa, un aumento de esta variable en un euro indicará una leve disminución de las ventas
- Gran parte de las variables son significativas en el modelo

Además, para el modelo entrenado para el conjunto de datos con varaibles factorizadas, la interacción entre el día de la semana y el mes es significativa, indicando una variación de las ventas en función de las distintas combinaciones de valores de estas variables.

De nuevo, el modelo seleccionado es el modelo para variables factorizadas, que nos da el menor valor del AIC, indicación de una mayor calidad del modelo estadístico.

- $AIC_{dummies} = 17366$
- $AIC_{factorizacion} = 13618$

Entrenamos el modelo seleccionado en los datos de entrenamiento haciendo uso de la función *predict*

En el siguiente gráfico podemos ver una representación de los valores observados respecto de los valores ajustados.

Volvemos a tener unos resultados pobres, el modelo es capaz de explicar el 0.1703046 % de la variabilidad del volumen de ventas para los datos de testeo, a pesar de explicar el 0.6519377 % de la la variabilidad para los datos de entrenamiento, es decir, el modelo ha "*aprendido*" los datos con los que ha entrenado pero no generaliza bien para nuevos datos.

El p-valor del test de bondad de ajuste: $0 < 0.05 = \alpha$ .No existen evidencias significativas para afirmar que se trate de un modelo es adecuadao.

Ventas de productos sin calcio

```
ModeloP_SIN_CALCIO_dummy =
  glm(VENTAS~PRECIO_MEDIO_IMPUESTOS+
              (LUNES+MARTES+MIERCOLES+JUEVES+VIERNES+SABADO+DOMINGO)+
              (AGOSTO+SEPTIEMBRE+OCTUBRE+NOVIEMBRE+DICIEMBRE+ENERO),
      family = poisson(link = "log"),
      data=Ventas_SIN_CALCIO_ENT_poiss)
#summary(ModeloP_SIN_CALCIO_dummy)
```

DATOS_SC	R2_SC	RMSE_SC
Datos entrenamiento	0.7117361	264.3933
Datos Test	0.2298473	385.9581

```
ModeloP_SIN_CALCIO_factor=
  glm(VENTAS~PRECIO_MEDIO_IMPUESTOS+DESCUENTO_MEDIO+
        DIA_SEMANA*MES,
      family = poisson(link = "log"),
      data=Ventas_SIN_CALCIO_ENT)
#summary(ModeloP_SIN_CALCIO_factor)
```

Para ambos modelos podemos afirmar:

- La variable precio medio es altamente significativa en ambos modelos, indicando que un aumento de esta variable en un euro indicará una leve disminución de las ventas
- Gran parte de las variables son significativas en el modelo

Además, para el modelo entrenado para el conjunto de datos con varaibles factorizadas, la interacción entre el día de la semana y el mes es significativa, indicando una variación de las ventas en función de las distintas combinaciones de valores de estas variables.

De nuevo, el modelo seleccionado es el modelo para variables factorizadas, que nos da el menor valor del AIC, indicación de una mayor calidad del modelo estadístico.

- $AIC_{dummies} = 12738$
- $AIC_{factorizacion} = 10153$

Entrenamos el modelo seleccionado en los datos de entrenamiento haciendo uso de la función *predict*.

Volvemos a tener unos resultados no demasiado buenos. Este modelo no es capaz de explicar más que el 0.2298473 % de la variabilidad del volumen de ventas en los datos de testeo, a pesar de explicar el 0.7117361 % para los datos de entrenamiento. Los errores cuadráticos medios son muy elevados en comparación con el volumen de ventas que se está prediciendo.

El p-valor del contraste de bondad de ajuste: $0 < 0.05 = \alpha$. No existen evidencias significativas para afirmar que se trate de un modelo es adecuadao.

Estos modelos se han desarrollando asumiendo que la distribución de las ventas diarias sigue una Poisson, caracterizándose esta distribución porque su esperanza y su varianza coinciden; pero esto no siempre ocurre trabajando con conjuntos de datos reales. Se dice entonces que el modelo presenta sobredispersión. Vamos a contrastar la presencia de sobredispersión en los modelos entrenados haciendo uso de la función *dispersiontest* de la librería *AER*

```
##
##  Overdispersion test
##
## data:  ModeloP_TOT_factor
## z = 3.232, p-value = 0.0006146
## alternative hypothesis: true dispersion is greater than 1
```

```
## sample estimates:
## dispersion
##   128.3092

##
##  Overdispersion test
##
## data:  ModeloP_CALCIO_factor
## z = 2.9585, p-value = 0.001546
## alternative hypothesis: true dispersion is greater than 1
## sample estimates:
## dispersion
##   83.85636

##
##  Overdispersion test
##
## data:  ModeloP_SIN_CALCIO_factor
## z = 3.349, p-value = 0.0004055
## alternative hypothesis: true dispersion is greater than 1
## sample estimates:
## dispersion
##   58.15924
```

Observamos que en los tres casos existe dispersión y junto con las conlusiones de los test de bondad de ajuste, podemos afirma que en este caso, el modelo de regresión de poisson no es adecuaado para modelar el volumen de ventas diario.

0.0.0.0.2. Modelo de Regresión Binomial Negativa

A continuación, modelaremos las ventas diarias según un modelo de regresión binomial negativa. No podemos hace uso de la función **glm** del paquete base de R debido a que no tiene implementada la opción de esta distribución. Por ese motivo, utilizaremos la función **glm.nb** de la librería *MASS*, que incluye la estimación del parámetro adicional θ. Los conjuntos de datos son los mismos que los utilizados en los modelos de regresión de poisson, al igual que las variables explicativas:

- Variables dummy/factorizadas del día de la semana y el mes del año
- Precio medio con impuestos y descuento
- Día de la semana
- Mes del año

0.0.0.0.2.1. Modelado

Ventas totales

```
ModeloBN_TOT_dummy =
  glm.nb(VENTAS~PRECIO_MEDIO_IMPUESTOS+DESCUENTO_MEDIO+
               (LUNES+MARTES+MIERCOLES+JUEVES+VIERNES+SABADO+DOMINGO)+
               (AGOSTO+SEPTIEMBRE+OCTUBRE+NOVIEMBRE+DICIEMBRE+ENERO),
       data=Ventas_TOTAL_ENT_poiss)
summary(ModeloBN_TOT_dummy)
```

```
##
## Call:
## glm.nb(formula = VENTAS ~ PRECIO_MEDIO_IMPUESTOS + DESCUENTO_MEDIO +
##     (LUNES + MARTES + MIERCOLES + JUEVES + VIERNES + SABADO +
##         DOMINGO) + (AGOSTO + SEPTIEMBRE + OCTUBRE + NOVIEMBRE +
##     DICIEMBRE + ENERO), data = Ventas_TOTAL_ENT_poiss, init.theta = 8.097463057,
##     link = log)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -6.8923  -0.3442   0.0136   0.2838   3.1876
##
## Coefficients: (2 not defined because of singularities)
##                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)            -7.691279  10.072299  -0.764   0.4451
## PRECIO_MEDIO_IMPUESTOS  9.022159   7.012513   1.287   0.1982
## DESCUENTO_MEDIO         0.003141   0.070215   0.045   0.9643
## LUNES1                  2.542272   0.109933  23.126   <2e-16 ***
## MARTES1                 2.420148   0.109578  22.086   <2e-16 ***
## MIERCOLES1              2.334101   0.111852  20.868   <2e-16 ***
## JUEVES1                 2.583267   0.114958  22.471   <2e-16 ***
## VIERNES1                2.429041   0.109431  22.197   <2e-16 ***
## SABADO1                 2.527554   0.112417  22.484   <2e-16 ***
## DOMINGO1                      NA         NA      NA       NA
## AGOSTO1                -0.194510   0.103896  -1.872   0.0612 .
## SEPTIEMBRE1            -0.038522   0.106291  -0.362   0.7170
## OCTUBRE1                0.124324   0.101660   1.223   0.2214
## NOVIEMBRE1             -0.069165   0.109784  -0.630   0.5287
## DICIEMBRE1              0.025662   0.104022   0.247   0.8051
## ENERO1                        NA         NA      NA       NA
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(8.0975) family taken to be 1)
##
##     Null deviance: 732.98  on 144  degrees of freedom
## Residual deviance: 149.26  on 131  degrees of freedom
## AIC: 2258.3
##
## Number of Fisher Scoring iterations: 1
##
##
##               Theta:  8.097
##           Std. Err.:  0.950
##
##  2 x log-likelihood:  -2228.334
```

Con la función *glm.nb*, obtenemos una salida parecida a la del modelo de regresión de poisson salvo por el parámetro de dispersión θ, estimado mediante el método de la máxima

verosimilitud, para el cual se obtiene un valor que no es el que aparece en la salida, sino su inversa: $\theta = 0.1234955$.

También podemos ver la estimación de los coeficientes del modelo y el estadístico de desviación, que sigue una distribución chi-cuadrado de 130 grados de libertad y tiene un valor de 149.24. Haciendo uso de este estadístico podemos evaluar la sobredispersión de los datos de la siguiente forma:

$$\frac{D}{gl} \implies \frac{149.24}{130} = 1.148 > 1$$

,

La relación anterior nos indica sobredispersión en los datos.

En este modelo, para un nivel de signifiación del 95 %, los coeficientes estimados para las varaibles descuento y precio medio pueden suponerse nulos, siendo en ambos casos el p-valor correspondiente mayor que $\alpha = 0.05$. Tampoco es significativo el mes del año, es decir, para este modelo, las única variable que influyen en el volumen de venta es el día de la semana.

Vamos ahora a entrenar el modelo para las variables factorizadas:

```
ModeloBN_TOT_factor= glm.nb(VENTAS~PRECIO_MEDIO_IMPUESTOS+
                            DIA_SEMANA+MES+DESCUENTO_MEDIO,
                          data=Ventas_TOTAL_ENT)
summary(ModeloBN_TOT_factor)
```

```
##
## Call:
## glm.nb(formula = VENTAS ~ PRECIO_MEDIO_IMPUESTOS + DIA_SEMANA +
##     MES + DESCUENTO_MEDIO, data = Ventas_TOTAL_ENT, init.theta = 8.097463057,
##     link = log)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -6.8923  -0.3442   0.0136   0.2838   3.1876
##
## Coefficients:
##                           Estimate Std. Error z value Pr(>|z|)
## (Intercept)             -5.149006  10.099274  -0.510   0.6102
## PRECIO_MEDIO_IMPUESTOS   9.022159   7.012513   1.287   0.1982
## DIA_SEMANA2             -0.122124   0.108148  -1.129   0.2588
## DIA_SEMANA3             -0.208171   0.113041  -1.842   0.0655 .
## DIA_SEMANA4              0.040995   0.112975   0.363   0.7167
## DIA_SEMANA5             -0.113231   0.106479  -1.063   0.2876
## DIA_SEMANA6             -0.014719   0.109275  -0.135   0.8929
## DIA_SEMANA7             -2.542272   0.109933 -23.126   <2e-16 ***
## MES8                    -0.194510   0.103896  -1.872   0.0612 .
## MES9                    -0.038522   0.106291  -0.362   0.7170
## MES10                    0.124324   0.101660   1.223   0.2214
## MES11                   -0.069165   0.109784  -0.630   0.5287
```

DATOS	R2	RMSE
Datos entrenamiento	0.6042761	689.2544
Datos Test	0.3773750	671.4281

```
## MES12                   0.025662   0.104022   0.247   0.8051
## DESCUENTO_MEDIO         0.003141   0.070215   0.045   0.9643
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(8.0975) family taken to be 1)
##
##     Null deviance: 732.98  on 144  degrees of freedom
## Residual deviance: 149.26  on 131  degrees of freedom
## AIC: 2258.3
##
## Number of Fisher Scoring iterations: 1
##
##
##               Theta:  8.097
##           Std. Err.:  0.950
##
##  2 x log-likelihood:  -2228.334
```

En este modelo, la única variable significativa es que el día de la compra sea o no domingo. La estimación del coeficiente $\hat{\beta}_{\text{Domingo}} = -2.542272 > 0$ podemos afirmar lo siguiente: ir a comprar un domingo, hará que el volumen de ventas disminuya ligeramente.

Para seleccionar un modelo adecuado, se ha hecho uso del criterio de información de Akaike, eligiendo aquel que nos de el menor AIC. A continuación se exponen los correspondientes valores del AIC para ambos modelos:

- Modelo con variables dummy: AIC=2258.3
- Modelo con variables factorizadas: AIC=2258.3

Ambos modelos tienen el mismo valor del AIC, pero seleccionamos el de las varaibles dummy, ya que hay mayor número de variables significas en el modelo.

A continuación, procedemos a entrenar el modelo seleccionado en los datos de entrenamiento haciendo uso de la función *predict*

A continuación mostramos una tabla con las métricas que nos dan el rendimiento del modelo

El modelo obtenido explica el 60.43 % de la variabilidad total de los datos en el conjunto de entrenamiento, y el 37.74 % para los datos de testeo. El valor del error cuadrático medio indica que el modelo se va a equivocar de media, en 671 ventas, que es un valor alto para el volumen de ventas que se está considerando, ya que hay días que se venden menos de 700 items.

Ventas de productos con calcio

DATOS_C	R2_C	RMSE_C
Datos entrenamiento	0.5556762	406.7701
Datos Test	0.3323618	381.1508

```
ModeloBN_CALCIO_dummy =
  glm.nb(VENTAS~PRECIO_MEDIO_IMPUESTOS+
              (LUNES+MARTES+MIERCOLES+JUEVES+VIERNES+SABADO+DOMINGO)+
              (AGOSTO+SEPTIEMBRE+OCTUBRE+NOVIEMBRE+DICIEMBRE+ENERO),
            data=Ventas_CALCIO_ENT_poiss)
#summary(ModeloBN_CALCIO_dummy)


ModeloBN_CALCIO_factor=
  glm(VENTAS~PRECIO_MEDIO_IMPUESTOS+DIA_SEMANA+MES,
              data=Ventas_CALCIO_ENT)
#summary(ModeloBN_CALCIO_factor)
```

- Para ambos modelos podemos afirmar que el mes del año no influye en el volumen de ventaas
- En el modelo con variables factorizadas volvemos a comprobar que la única varaible significativa al 95 %, y por tanto, la única cuyo coeficiente no es nulo es si la compra se ha realizado o no un Domingo.
- Sobredispersión del modelo con variables dummies: $\frac{D}{gl} \implies \frac{150.50}{132} = 1.14 > 1.$ Existe sobredispersión.

De nuevo, el modelo seleccionado es el modelo que utiliza variable dummies, que nos da el menor valor del AIC, indicación de una mayor calidad del modelo estadístico.

- $AIC_{dummies} = 2084.4575261$
- $AIC_{factorizacion} = 2184.5184669$

Entrenamos el modelo seleccionado en los datos de entrenamiento haciendo uso de la función *predict*

En el siguiente gráfico podemos ver una representación de los valores observados respecto de los valores ajustados.

Este modelo es capaz de explicar el 0.3323618 % de la variabilidad del volumen de ventas para los datos de testeo, a pesar de explicar el 0.5556762 % de la la variabilidad para los datos de entrenamiento. A pesar de obtener estos resultados, el error cuadrático medio cometido es menor en los datos de testeo, pero aún bastante alto para el volumen de ventas diario de los productos con calcio.

Ventas de productos sin calcio

```
ModeloBN_SIN_CALCIO_dummy =
  glm.nb(VENTAS~PRECIO_MEDIO_IMPUESTOS+
              (LUNES+MARTES+MIERCOLES+JUEVES+VIERNES+SABADO+DOMINGO)+
              (AGOSTO+SEPTIEMBRE+OCTUBRE+NOVIEMBRE+DICIEMBRE+ENERO),
```

```
    data=Ventas_SIN_CALCIO_ENT_poiss)
summary(ModeloBN_SIN_CALCIO_dummy)
```

```
##
## Call:
## glm.nb(formula = VENTAS ~ PRECIO_MEDIO_IMPUESTOS + (LUNES + MARTES +
##     MIERCOLES + JUEVES + VIERNES + SABADO + DOMINGO) + (AGOSTO +
##     SEPTIEMBRE + OCTUBRE + NOVIEMBRE + DICIEMBRE + ENERO), data = Ventas_SIN_CALCI
##     init.theta = 8.630186979, link = log)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -6.8783  -0.3628   0.0259   0.2892   3.1197
##
## Coefficients: (2 not defined because of singularities)
##                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)            127.15879   99.60523   1.277    0.202
## PRECIO_MEDIO_IMPUESTOS -88.21251   71.67668  -1.231    0.218
## LUNES1                   2.48641    0.10472  23.744   <2e-16 ***
## MARTES1                  2.36936    0.10581  22.392   <2e-16 ***
## MIERCOLES1               2.26740    0.10926  20.752   <2e-16 ***
## JUEVES1                  2.51565    0.10998  22.873   <2e-16 ***
## VIERNES1                 2.37043    0.10525  22.521   <2e-16 ***
## SABADO1                  2.46998    0.10843  22.779   <2e-16 ***
## DOMINGO1                      NA         NA      NA       NA
## AGOSTO1                 -0.13603    0.10629  -1.280    0.201
## SEPTIEMBRE1              0.03397    0.10776   0.315    0.753
## OCTUBRE1                 0.17653    0.10445   1.690    0.091 .
## NOVIEMBRE1              -0.01951    0.10528  -0.185    0.853
## DICIEMBRE1               0.03895    0.10244   0.380    0.704
## ENERO1                        NA         NA      NA       NA
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(8.6302) family taken to be 1)
##
##     Null deviance: 731.62  on 144  degrees of freedom
## Residual deviance: 149.92  on 132  degrees of freedom
## AIC: 2035.3
##
## Number of Fisher Scoring iterations: 1
##
##
##               Theta:  8.63
##           Std. Err.:  1.03
##
##  2 x log-likelihood:  -2007.284
```

```
ModeloBN_SIN_CALCIO_factor=
  glm.nb(VENTAS~PRECIO_MEDIO_IMPUESTOS+DESCUENTO_MEDIO+
         DIA_SEMANA+MES,
       data=Ventas_SIN_CALCIO_ENT)
summary(ModeloBN_SIN_CALCIO_factor)
```

```
##
## Call:
## glm.nb(formula = VENTAS ~ PRECIO_MEDIO_IMPUESTOS + DESCUENTO_MEDIO +
##     DIA_SEMANA + MES, data = Ventas_SIN_CALCIO_ENT, init.theta = 8.632431053,
##     link = log)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -6.8768  -0.3554   0.0293   0.2958   3.1181
##
## Coefficients:
##                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)            130.54413   99.62747   1.310   0.1901
## PRECIO_MEDIO_IMPUESTOS -88.85924   71.70100  -1.239   0.2152
## DESCUENTO_MEDIO          0.01415    0.07050   0.201   0.8409
## DIA_SEMANA2             -0.11759    0.10476  -1.122   0.2617
## DIA_SEMANA3             -0.22089    0.10884  -2.029   0.0424 *
## DIA_SEMANA4              0.02837    0.10991   0.258   0.7963
## DIA_SEMANA5             -0.11621    0.10338  -1.124   0.2610
## DIA_SEMANA6             -0.01740    0.10618  -0.164   0.8698
## DIA_SEMANA7             -2.48790    0.10497 -23.702   <2e-16 ***
## MES8                    -0.13566    0.10628  -1.276   0.2018
## MES9                     0.03440    0.10775   0.319   0.7495
## MES10                    0.17679    0.10444   1.693   0.0905 .
## MES11                   -0.02658    0.11117  -0.239   0.8110
## MES12                    0.03936    0.10244   0.384   0.7008
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(8.6324) family taken to be 1)
##
##     Null deviance: 731.80  on 144  degrees of freedom
## Residual deviance: 149.92  on 131  degrees of freedom
## AIC: 2037.2
##
## Number of Fisher Scoring iterations: 1
##
##
##               Theta:  8.63
##           Std. Err.:  1.03
##
##  2 x log-likelihood:  -2007.246
```

DATOS_SC	R2_SC	RMSE_SC
Datos entrenamiento	0.6226376	302.5125
Datos Test	0.3531053	325.3345

Se han obtenido resultados muy similares al resto:

- Para ambos modelos podemos afirmar que el mes del año no influye en el volumen de ventaas
- En este caso, para el modelo con variables factorizadas existen dos varaibles significativas que sea Domingo o Miércoles.
- Sobredispersión del modelo: $\frac{D}{gl} \implies \frac{149.92}{132} = 1.13 > 1$. Existe sobredispersión. Nota: estos grados de libertad son los del modelo con variables dummies, pero en el segundo modelo, el estadístico de desviación tiene 131 grados de libertad, y por tanto, el resultado es el mismo.

El modelo seleccionado es el modelo que utiliza variable dummies, que nos da el menor valor del AIC, indicación de una mayor calidad del modelo estadístico.

- $AIC_{dummies} = 2035.2843631$
- $AIC_{factorizacion} = 2037.2463812$

Entrenamos el modelo seleccionado en los datos de entrenamiento haciendo uso de la función *predict*.

Este modelo no es capaz de explicar más que el 0.3531053 % de la variabilidad del volumen de ventas en los datos de testeo, explicando el 0.6226376 % de la variabilidad de ventas para los datos de entrenamiento. Los errores cuadráticos medios son muy elevados en comparación con el volumen de ventas que se está prediciendo.

0.0.0.0.3. Conclusiones

0.0.0.0.4. Análisis de Series Temporales

Se consideró aplicar un análisis de series temporales debido a la estructura de los datos, ya que este tipo de análisis contempla la estructura temporal de los mismos. Como ya se avanzó en el desarrollo teórico, aplicaremos la metodología Box-Jenkis, la cual tiene en cuenta la dependencia existente de los datos, construyendo así un modelo ARIMA.

Trataremos de modelizar el volumen de ventas total según día de la semana. Para construir la serie, primero hemos añadido los días 25 de Diciembre y 1 de Enero con un número de ventas 0, ya que, si no se tomaba esta decisión, la serie ya no estaría definida según la realidad.

0.0.0.0.4.1. Creación ST y representación de los datos

Los datos que se han utilizado para el análisis han sido las ventas totales para cada día, agrupando los datos según día de la semana, obteniendo así datos con período S=7.

Sin embargo, si construimos la serie con los valores actuales, no podremos aplicarle transformaciones, en particular la transformación de Box-Cox, ya que existen dos valores

nulos, las ventas para los días 25 de Diciembre y 1 de Enero. Por este motivo, sumamos una constante a todas las observaciones de modo que sean todas positivas.

Nota: la constante que hemos sumado es de 10 unidades.

El primer dato, indica que el sábado de la semana 31 del año se vendieron un total de 2049 artículos, aunque en la realidad es que se vendieron 10 unidades menos, pero se le ha sumado una constante a la serie.

```
tsDiaSemanal = ts(Ventas_Totales_Dia_Semana_Completo$ArtVendidos,
                  frequency=7, # Período
                  start=c(31,6) # Semana 36, sábado
                  )
print(tsDiaSemanal,calendar=TRUE)
```

```
##       p1   p2   p3   p4   p5   p6   p7
## 31                          2049  216
## 32 2418 1955 1648 1798 1783 2005  194
## 33 2140 1518 1698 1615 2040  408  268
## 34 2501 1957 1447 1470 1649 1993  165
## 35 2304 1938 1853 1776 1822 2505  194
## 36 2390 1988 2289 2025 2153 2335  247
## 37 2503 1987 2159 2060  502 3088  249
## 38 2495 2228 2266 1979 1969 2490  241
## 39 2134 2105 2110 1527 2914 2693  174
## 40 2618 2079 2066 2186 2429 2978  178
## 41 2275 2403 2010 2136 2255 2940  220
## 42  410 2972 2502 8021 2343 2942  202
## 43 2258 1835 1677 1821 2410 2611  268
## 44 2391 2495 2396 2538 2445 2568  181
## 45 2433 2185 2317 2307 2367 2631  144
## 46 2396 2010 2073 2130 2491 2960  173
## 47 2407 2013 1876 2218 2252 2575  159
## 48 2143 2181 2274 2018 2667 3050  136
## 49 2499 2252 2242 2019 2358 2899  133
## 50 2372  319 2450 2216 2486 2870  117
## 51 2153 2169 1611 6979 2164 2830  271
## 52 2113 2292 2804 2100   10  350  358
## 53 3014 2780 2647 2023   10 2652  201
## 54 2961 2908   40 2609 2894 2556  171
## 55 2502 2506 2126 2068 2617 2869  109
## 56 2409 2163 1840 2110 2443 3002  128
## 57 2417 2104 2383 2316 2631 2976
```

Después de haber definido los datos como una serie temporal, visualizamos la evolución de la serie en el tiempo.

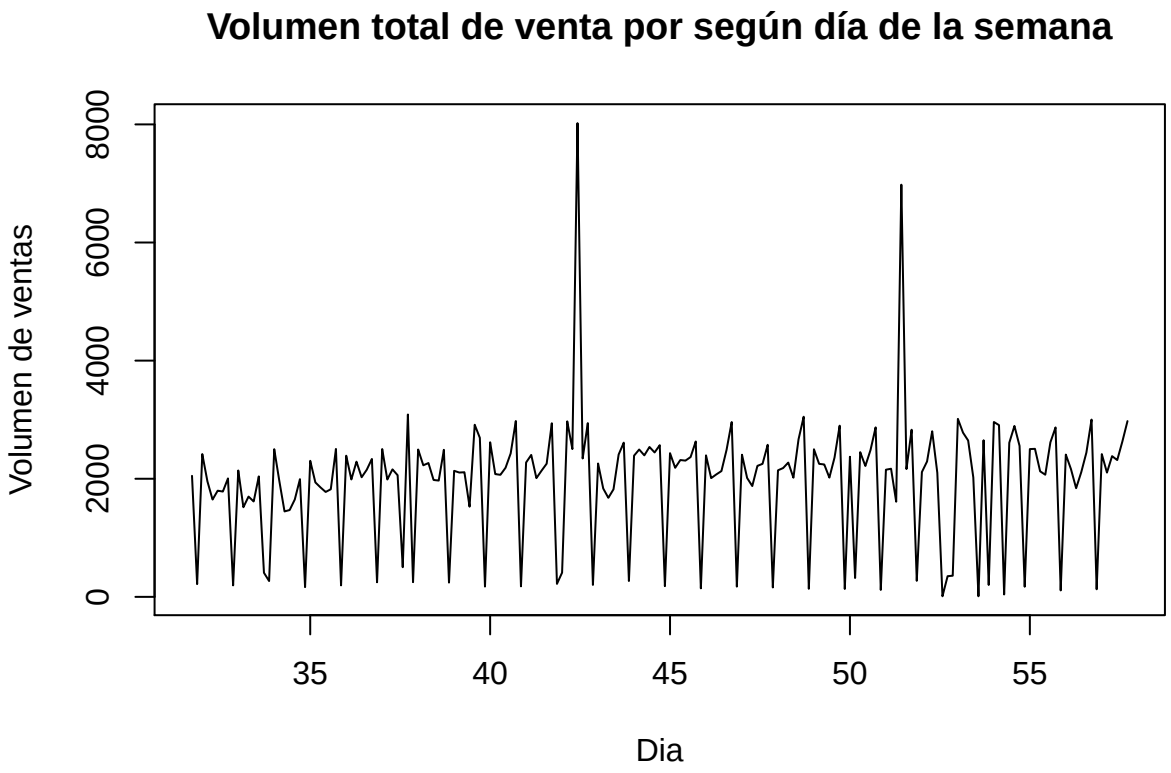

En el gráfico se puede apreciar cierta estacionalidad de los datos, es decir, movimientos que se repiten regularmente año trás año en los mismo períodos. También observamos que las oscilaciones van aumentando con el tiempo, indicando que la varianza no es constante. Por este motivo, debemos hacer alguna transformación para que la varianza sea constante en el tiempo.

0.0.0.0.4.2. Transformación de BoxCox para estabilizar la varianza

Para encontrar una transformación que haga que la varianza sea constante en el tiempo, haremos uso de la familia de transformaciones Box-Cox con ayuda de la librería *TSA*.

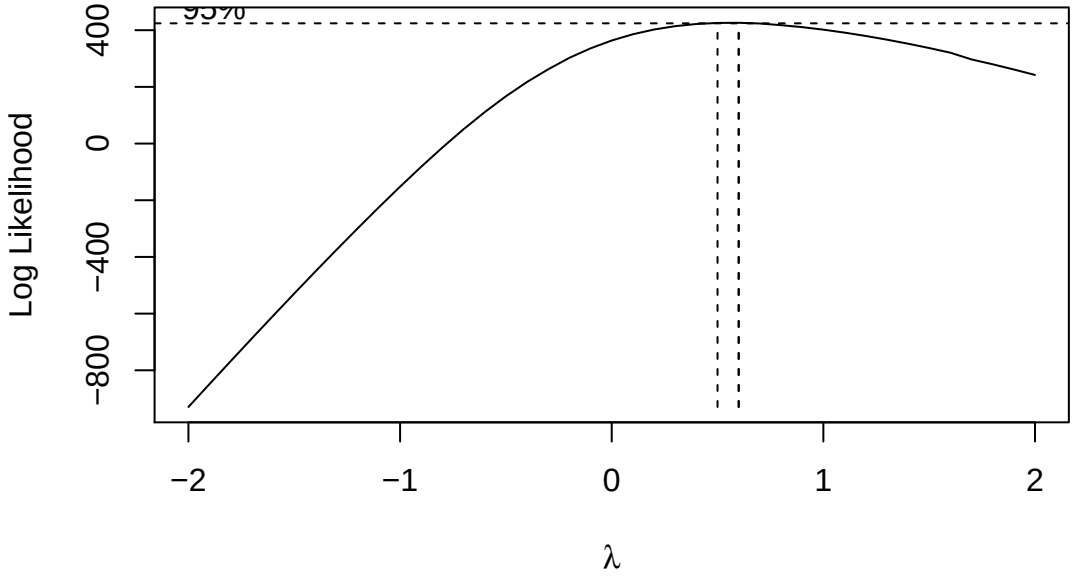

La función *BoxCox.ar* sugiere un óptimo de $\lambda = 0.6$, con un intervalo de confianza al 95 %: (0.5,0.6). Se necesita una transformación sencilla y comprensible, por lo que se ha obtado por tomar como valor de lambda el extremo inferior del intervalo, $\lambda = 1/2$.

Transformamos los datos y volvemos a representar la serie.

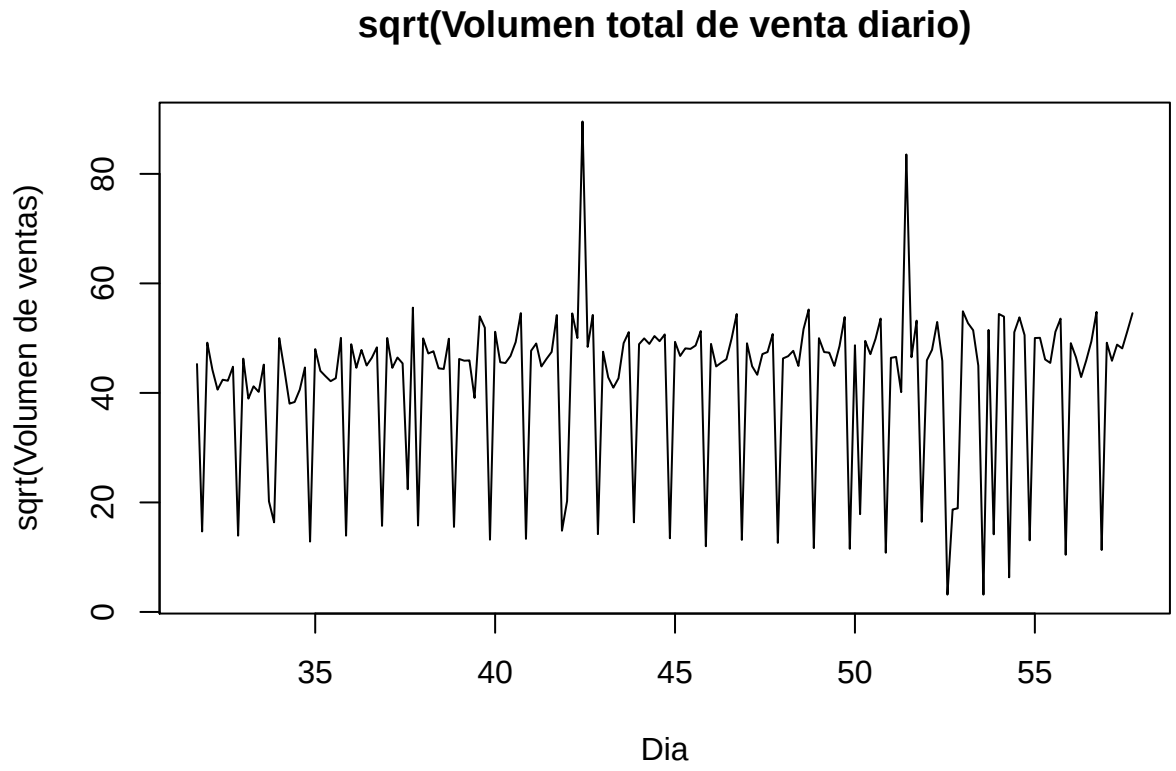

0.0.0.0.4.3. Transformaciones para estabilizar la media

Vamos a estudiar si el motivo de la no estacionalidad de los datos en media se debe a que se trata de un proceso integrado. Para ello, hacemos uso de la función de autocorrelación simple.

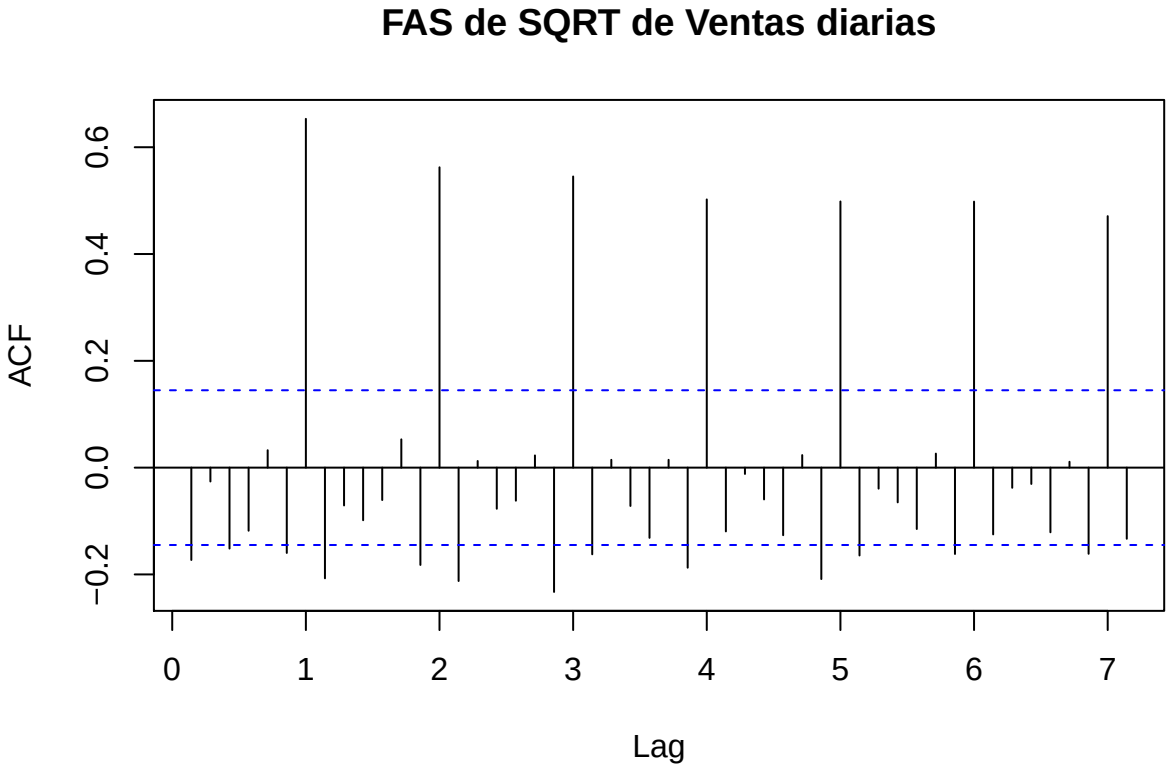

La FAS muestral decrece de lentamente en los retardos estacionales de período 7, indicando

que estamos ante un modelo integrado. Debido a esta situación, hacemos una diferencia estacional de la serie y volvemos a representar la FAS (s=7).

```
tsDiaria_DifEst = diff(tsDiaSemanal_transf,lag=7,diff=1)
acf(tsDiaria_DifEst, main="FAS de primera diferencia estacional", lag=50)
```

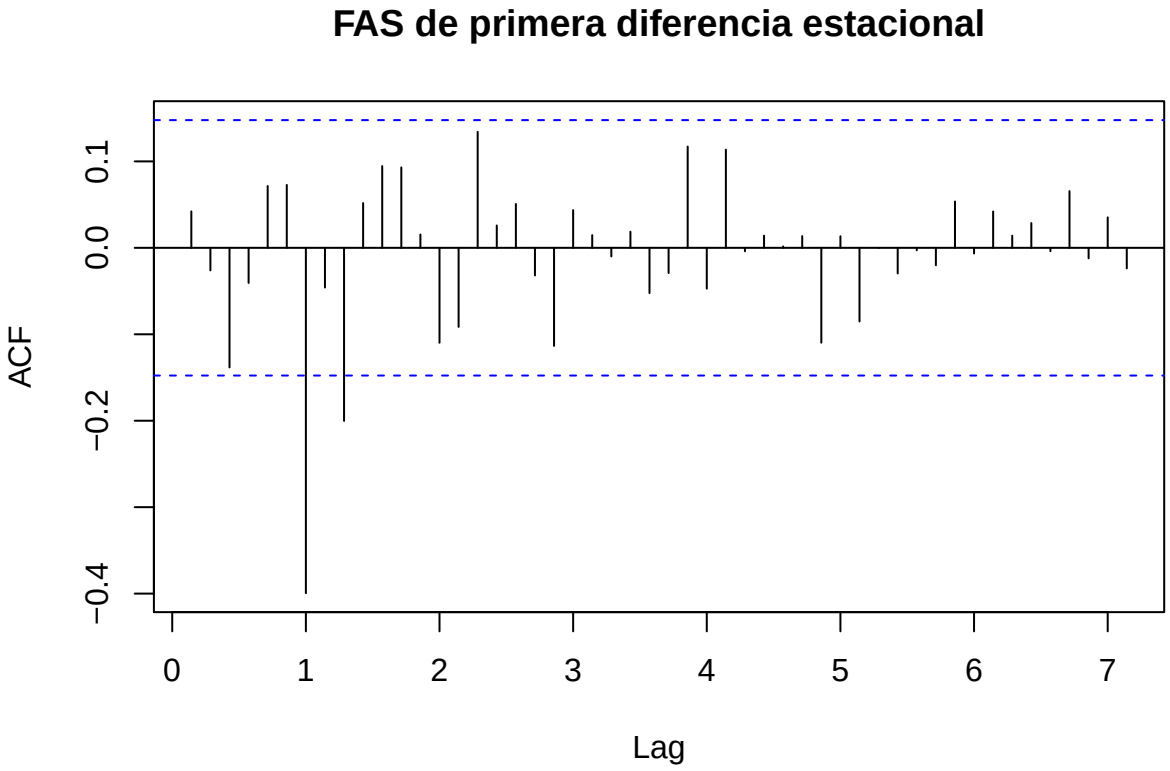

Ahora la función de autocorrelación muestral corresponde a la de un proceso estacionario. Por último, representamos gráficamente la serie diferenciada:

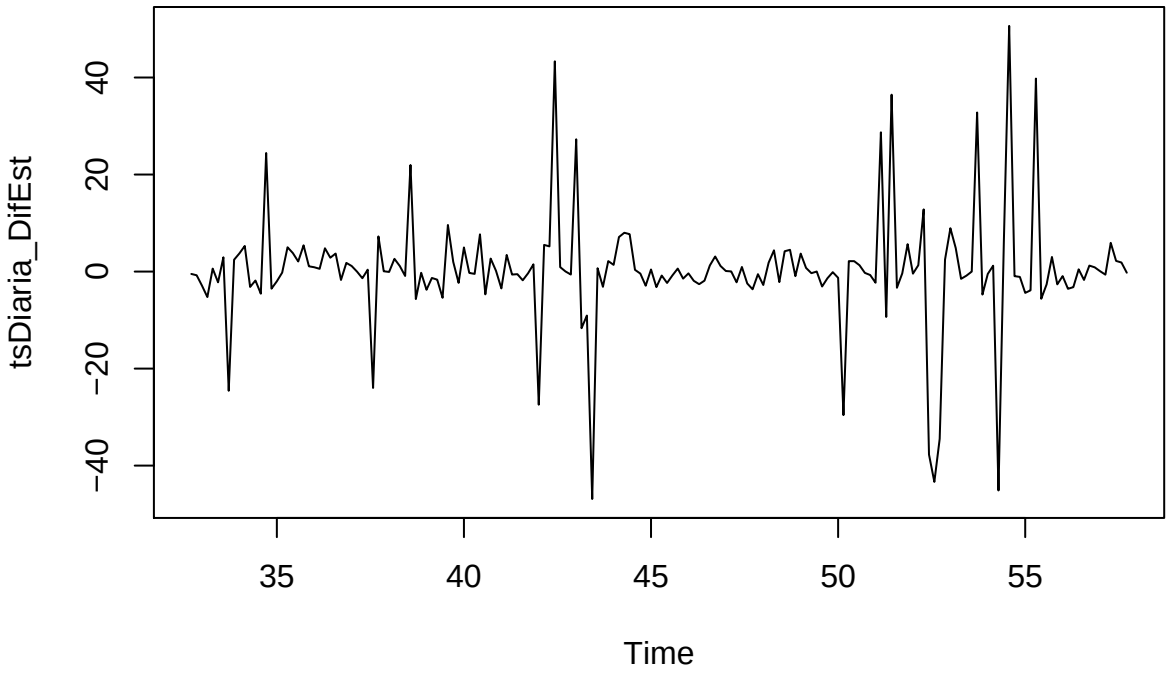

Observamos que la serie no muestra ningún comportamiento en particular, sino que se aprecia aleatoriedad, por lo que se podría pensar, que nos encontramos ante un proceso estacionario. Ahora estamos en condiciones de buscar un modelo estacionario para la serie.

0.0.0.0.4.4. Contraste de estacionariedad

Para confirmar la estacionariedad de los datos sugerida con la observación de la gráfica, necesitamos aplicar un test de hipótesis. Aplicamos el test de raíz unitaria de Dikey-Fuller, donde se contrasta la estacionariedad de los datos a través del siguiente test de hipótesis:

$$\begin{cases} H_0: & \text{El polinomio autoregresivo tiene una raíz unitaria} \\ H_1: & \text{Todas las raíces del polinomio autoregresivo son estacionarias} \end{cases}$$

```
##
##  Augmented Dickey-Fuller Test
##
## data:  tsDiaria_DifEst
## Dickey-Fuller = -5.1008, Lag order = 5, p-value = 0.01
## alternative hypothesis: stationary
```

El p-valor del test$= 0.01 < 0.05 = \alpha$, y por tanto concluímos que no existen evidencias significativas para asumir que el polinomio autoregresivo tiene alguna raíz unitaria, la serie es estacionaria.

0.0.0.0.4.5. Identificación de la estructura ARIMA de la serie

Trataremos de identificar la estructura ARIMA más adecuada para esta serie a través de la función de autocorrelación simple (FAC) y de la función de autocorrelación parcial (FAP). Determinar el modelo más adecuado consistirá en e identificar el orden de los procesos de medias móviles y autoregresivos de la componente estacional y la componente regular.

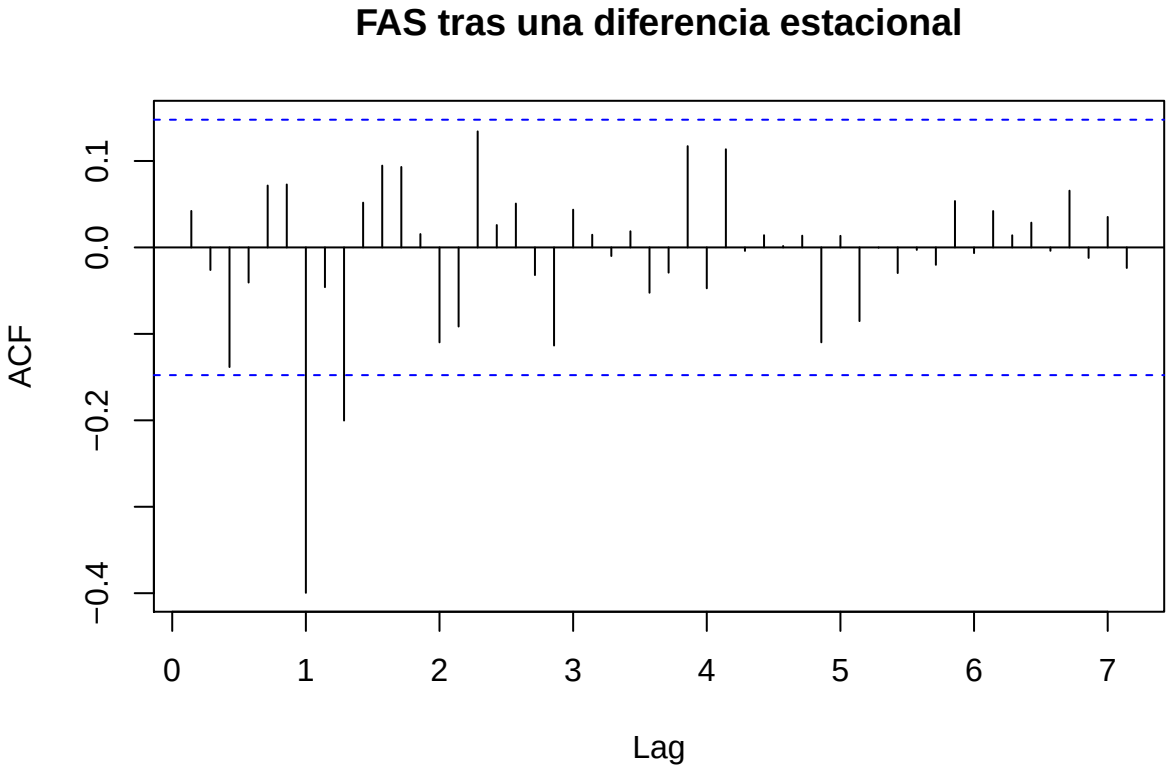

- Parte regular: En los primeros retardos no observamos ninguna autocorrelación significativamente no nula, indicando que el modelo tiene una estructura ARMA(0,0) en la parte regular.

- Parte estacional: Observamos una autocorrelación en el primer retardo estacional, por lo que parecería que la parte estacional tiene una estructura $MA(1)_{12}$.

Vamos a comprobar estos supuestos con la FAP.

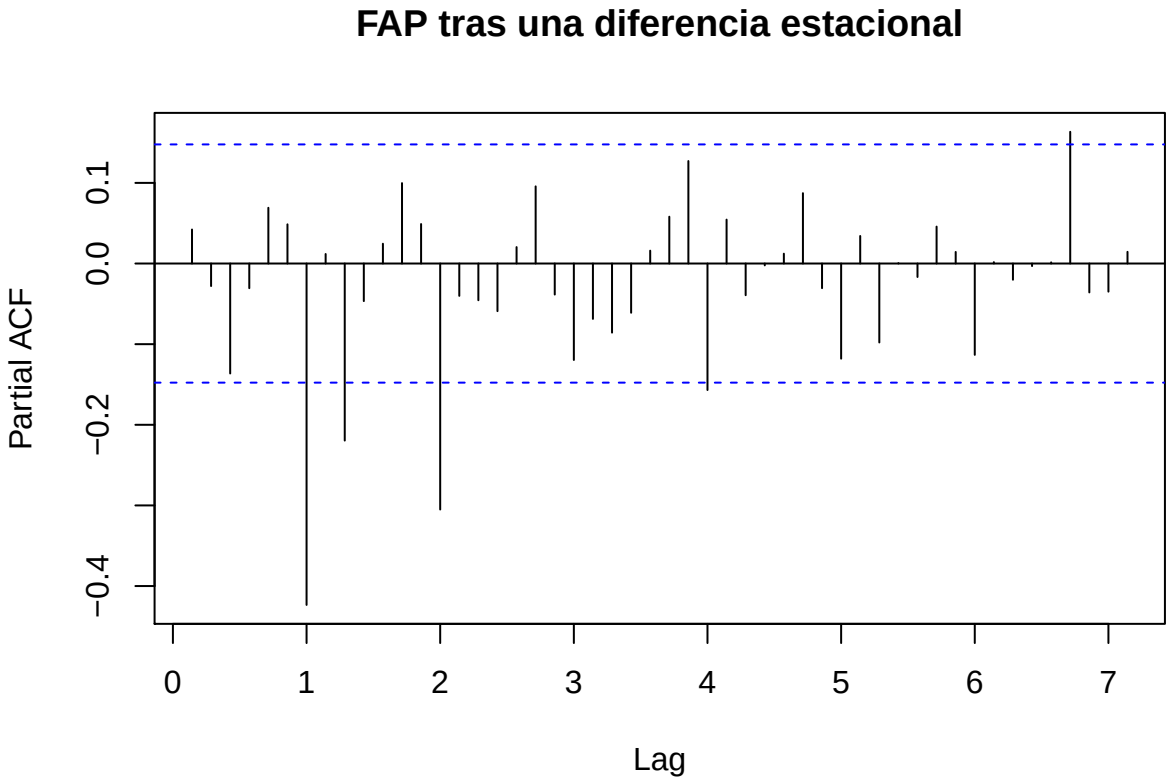

- Parte regular: De nuevo, no hay autocorrelaciones significativamente no nulas en los primeros retardos.
- Parte estacional: En los retardos estacionales, observamos como las autocorrelaciones decrecen rápidamente y a su izquierda, no hay autocorrelaciones significativamente no nulas, lo que avalaría aún más la suposición de un MA(1) en la parte estacional. Modelo propuesto: $MA(1)_{12}$

También observamos como hay otras autocorrelaciones significativamente no nulas, pero esto es debido a que se trata de un intervalo de confianza al 95 %, por lo que cabe esperar que haya algunas autocorrelaciones fuera de las bandas.

El modelo a considerar es un modelo estacional multiplicativo integrado de medias móviles puro: $ARIMA(0,1,1)_{12}$

0.0.0.0.4.6. Estimación de parámetros y diagnóstico del modelo

Una vez hemos obtenido un modelo, se han estimado sus parámetros con la función *arima*.

```
Ajuste1 = arima( tsDiaria_DifEst ,   # Serie trás una diferencia estacional
                 seasonal = list(order=c(0,0,1),period=7 ))
Ajuste1
```

```
##
## Call:
## arima(x = tsDiaria_DifEst, seasonal = list(order = c(0, 0, 1), period = 7))
##
```

```
## Coefficients:
##          sma1  intercept
##       -1.0000     0.0898
## s.e.   0.0827     0.0871
##
## sigma^2 estimated as 79.04:  log likelihood = -645.71,  aic = 1295.42
```

Trás comprobar si los coeficientes estimados son o no significativamente nulos, procedemos a eliminar la media del modelo, obteniendo así uno donde todos los coeficientes son significativamente no nulos.

```
##                  2.5 %     97.5 %
## sma1      -1.16213365 -0.8378657
## intercept -0.08097887  0.2605421
```

```
Ajuste1_1 = arima( tsDiaria_DifEst ,   # Serie trás una diferencia estacional
                   order = c(0,0,0),seasonal = list(order=c(0,0,1),period=7),
                  include.mean = FALSE # Eliminamos la media
                  )
Ajuste1_1
```

```
##
## Call:
## arima(x = tsDiaria_DifEst, order = c(0, 0, 0), seasonal = list(order = c(0,
##     0, 1), period = 7), include.mean = FALSE)
##
## Coefficients:
##          sma1
##       -0.9999
## s.e.   0.1009
##
## sigma^2 estimated as 79.52:  log likelihood = -646.24,  aic = 1294.47
```

```
confint(Ajuste1_1)
```

```
##          2.5 %     97.5 %
## sma1 -1.197648 -0.8021465
```

El modelo ajustado corresponde a la siguiente ecuación:

$$Y_t = (1 - L^7)(1 + 0.9999\Theta^7)\alpha_t, \qquad \alpha_t \sim RB(0, \sigma^2)$$

Para comprobar si el modelo es o no adecuado, comprobamos su validez a través de la diagnosis de los resíduos y concluímos que este ajuste no es adecuado, ya que según el Test de Ljung-Box, no existen evidencias significativas para aceptar la incorrelación de los resíduos: p-valor $= 0.002524 < 0.05 = \alpha$. Además, gráficamente podemos observar que los resíduos no se comportan como un ruido blanco.

```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(0,0,0)(0,0,1)[7] with zero mean
```

```
## Q* = 31.855, df = 13, p-value = 0.002524
##
## Model df: 1.   Total lags used: 14
```

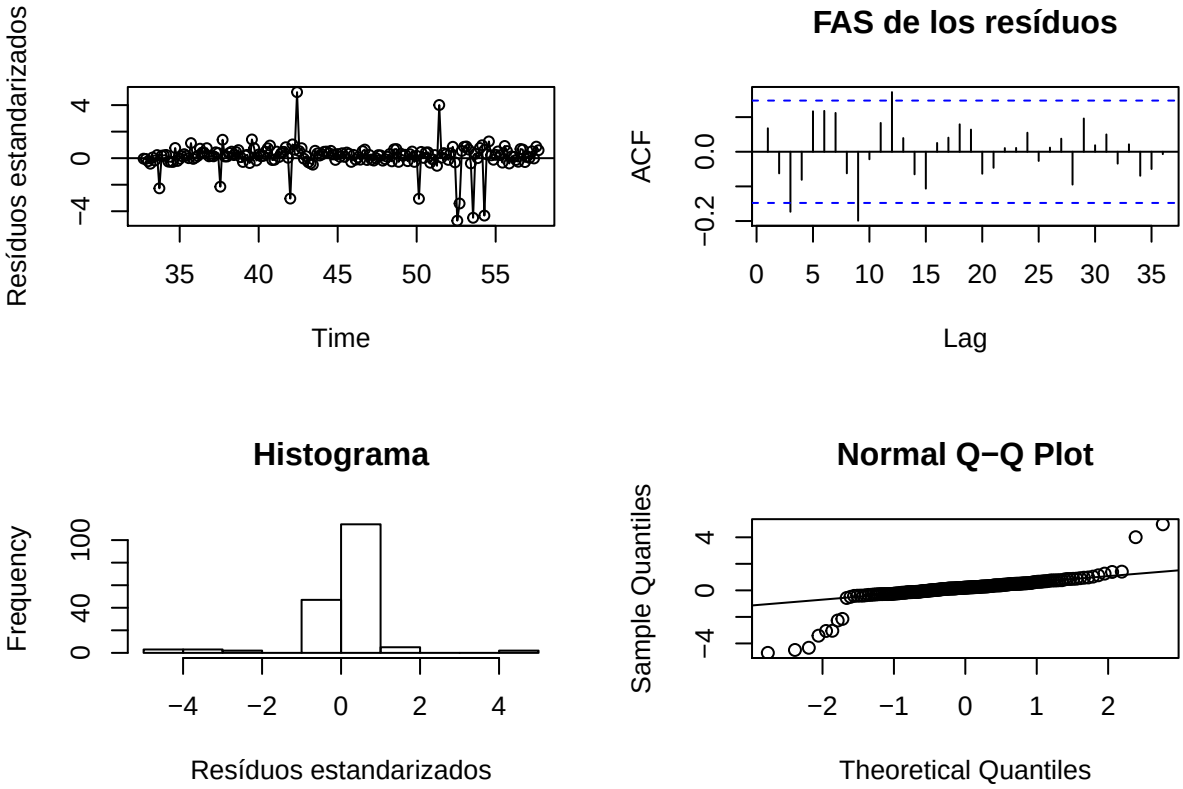

Vamos a probar otro modelo, en particular, a través del paquete *forecast* haciendo uso de la función *auto.arima*, que busca un modelo que minimiza el AIC.

```
## Series: tsDiaSemanal_transf
## ARIMA(1,0,0)(2,1,0)[7]
##
## Coefficients:
##          ar1     sar1     sar2
##       0.0709  -0.5180  -0.3068
## s.e.  0.0754   0.0708   0.0694
##
## sigma^2 = 106.2:  log likelihood = -660.08
## AIC=1328.17   AICc=1328.4   BIC=1340.85
```

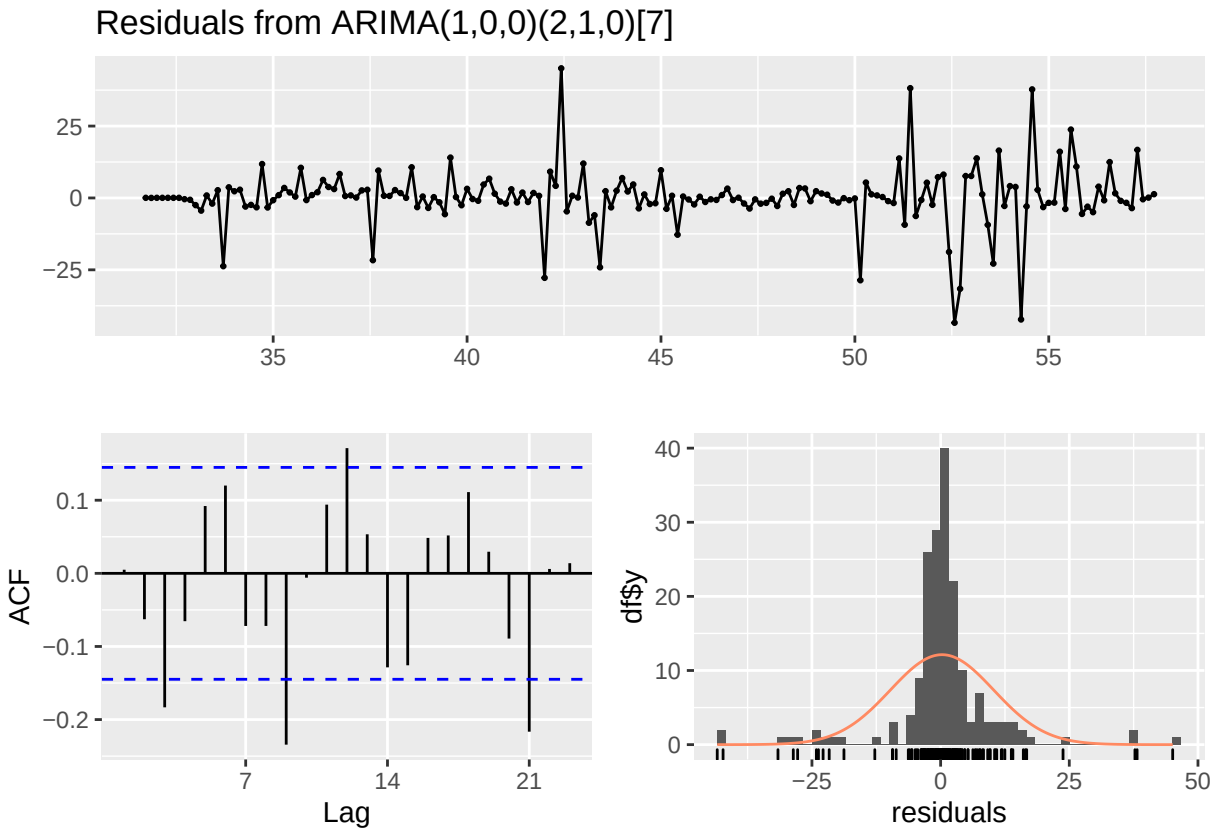


```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(1,0,0)(2,1,0)[7]
## Q* = 36.336, df = 11, p-value = 0.0001488
##
## Model df: 3.   Total lags used: 14
```

El ajuste propuesto es un modelo: $ARIMA(1,0,0)xARIMA(2,0,0)_7$, pero tampoco es adecuado, ya que volvemos a rechazar la hipótesis de incorrelación de los resíduos del Test de Ljung-Box.

No hemos podido encontrar un modelo adecuado que se ajuste a los datos y que pase la diagnosis, ya que los resíduos no provenían en ningún caso de un proceso de ruido blanco, es decir, no estaban incorrelados entre sí. Por este motivo, al no ser los retardos independientes, un retardo puede guardar cierta relación con otro retardo k períodos después. En estos casos, la autocorrelación puede conducir a una inexactitud en el modelo predictivo, que nos llevaría a interpretaciones erróneas.

La tabla mostrada a continuación expone los diferentes modelos ajutado, el valor del AIC y el p-valor obtenido del test de Ljung-Box. De haber pasado algún modelo la diagnosis, el seleccionado para realizar predicciones del volumen de ventas habría sido aquel con menor valor del AIC.

	MODELO	AIC	p-valor
Modelo 1	ARIMA(0,1,1)_7	1294.474	0.0025242
Modelo 2	ARIMA(1,0,0)x(2,1,0)_7	1328.403	0.0001488
Modelo 3	ARIMA(1,1,1)_7	1293.397	0.0068141
Modelo 4	ARIMA(1,1,0)_7	1341.251	0.0000002

Note:

El p-valor corresponde al test de Ljung-Box